

# Student Social Behavior Clustering using Unsupervised Learning

Presented By : Mayra Nur Fatikha





# About Me

---



## Mayra Nur Fatikha

*Fresh Graduate*

- [mayraatika@gmail.com](mailto:mayraatika@gmail.com) | **0895396345070**
- [linkedin.com/in/mayranf](https://www.linkedin.com/in/mayranf)

### Education

S1 Biology – Universitas Brawijaya

### Experience

- Intern Researcher – Badan Riset dan Inovasi Nasional
- Intern Researcher – Suranaree University of Technology, Thailand
- Practicum Assistant – Ecological Sciences
- Practicum Assistant – Basic Biocomputation

### Organizational Experience

- Head of Media Information and IT Department – BEM FMIPA UB
- Staff – Communication & Information Bureau – BEM FMIPA UB

### Skills

Technical: Microsoft Excel, Python (Basic), Adobe Photoshop, Canva, WordPress

Soft Skills: Analytical Thinking, Teamwork, Problem Solving, Adaptability, Communication

# About Dataset

- ✓ Dataset berisi **15.000** profil siswa SMA pada media sosial (**2006–2009**)
- ✓ Data mencakup minat siswa hasil **text mining** dan **informasi demografis**
- ✓ Tingginya **kompleksitas data** menyulitkan identifikasi pola secara manual
- ✓ **Clustering** digunakan untuk menemukan kelompok siswa dengan karakteristik dan minat serupa



## Objective

- ✓ Tujuan utama dari analisis ini adalah untuk menerapkan metode **unsupervised learning** melalui **clustering** guna **mengelompokkan** siswa sekolah menengah berdasarkan **pola minat, aktivitas sosial, dan karakteristik demografis** yang tercermin dari profil media sosial mereka

## Research Question

- ✓ Apakah terdapat tipe siswa dengan **karakteristik tertentu**?
- ✓ Apa **ciri utama** yang **membedakan** tiap cluster?
- ✓ Bagaimana **profil demografis** pada setiap cluster?

# Data Understanding

## 1. Student Demographic

- **Grad Year** (int) = Tahun kelulusan siswa sekolah menengah
- **Gender** (obj) = Jenis kelamin siswa
- **NumberOfFriends** (int) = Jumlah teman/koneksi siswa di media sosial

## 2. Kolom Minat & Aktivitas

Merepresentasikan frekuensi kemunculan kata tertentu dalam profil media sosial siswa



### SPORTS

basketball, football, soccer,  
softball, volleyball,  
swimming, cheerleading,  
baseball, tennis, sports



### ART

dance, band, marching,  
music, rock




### FASHION

hair, dress, blonde



# Data Preprocessing



EDA

Cek Missing Value  
& Duplikasi

- 996 *missing value*
- 2953 *duplikasi*

Pra-Modeling


- Digunakan kolom numerik
- Dilakukan standarisasi dengan StandardScaler

Pemodelan & Visualisasi Cluster

- PCA Analysis & Tuning Hyperparameter
- Visualisasi cluster
- Evaluasi


Cek Outlier

- 9404 baris
- Tidak dilakukan **drop**, agar cluster **representatif**
- Handling dengan **standarisasi**






### Distribusi Gender




- Mayoritas siswa dalam dataset adalah **perempuan** ( $\approx 80,3\%$ ), laki-laki hanya  $\approx 19,7\%$
- Dataset **tidak seimbang** secara gender, sehingga hasil **clustering** kemungkinan akan **lebih merepresentasikan** pola perilaku siswa perempuan

### Jumlah Siswa Berdasarkan Graduation Year




- Jumlah siswa relatif **merata** di setiap tahun kelulusan (2006–2009)
- Hal ini menunjukkan **proses pengambilan data yang konsisten** serta distribusi angkatan yang cukup seimbang


### Distribusi Jumlah teman/koneksi siswa di media sosial



- Distribusi jumlah teman menunjukkan pola ***right-skewed***, di mana sebagian besar siswa memiliki jumlah teman yang relatif rendah
- Mayoritas siswa memiliki jumlah teman **di bawah 100**, dengan konsentrasi tertinggi pada rentang jumlah teman yang kecil
- Pola ini mengindikasikan adanya **ketimpangan** tingkat keterhubungan sosial antar siswa di media sosial



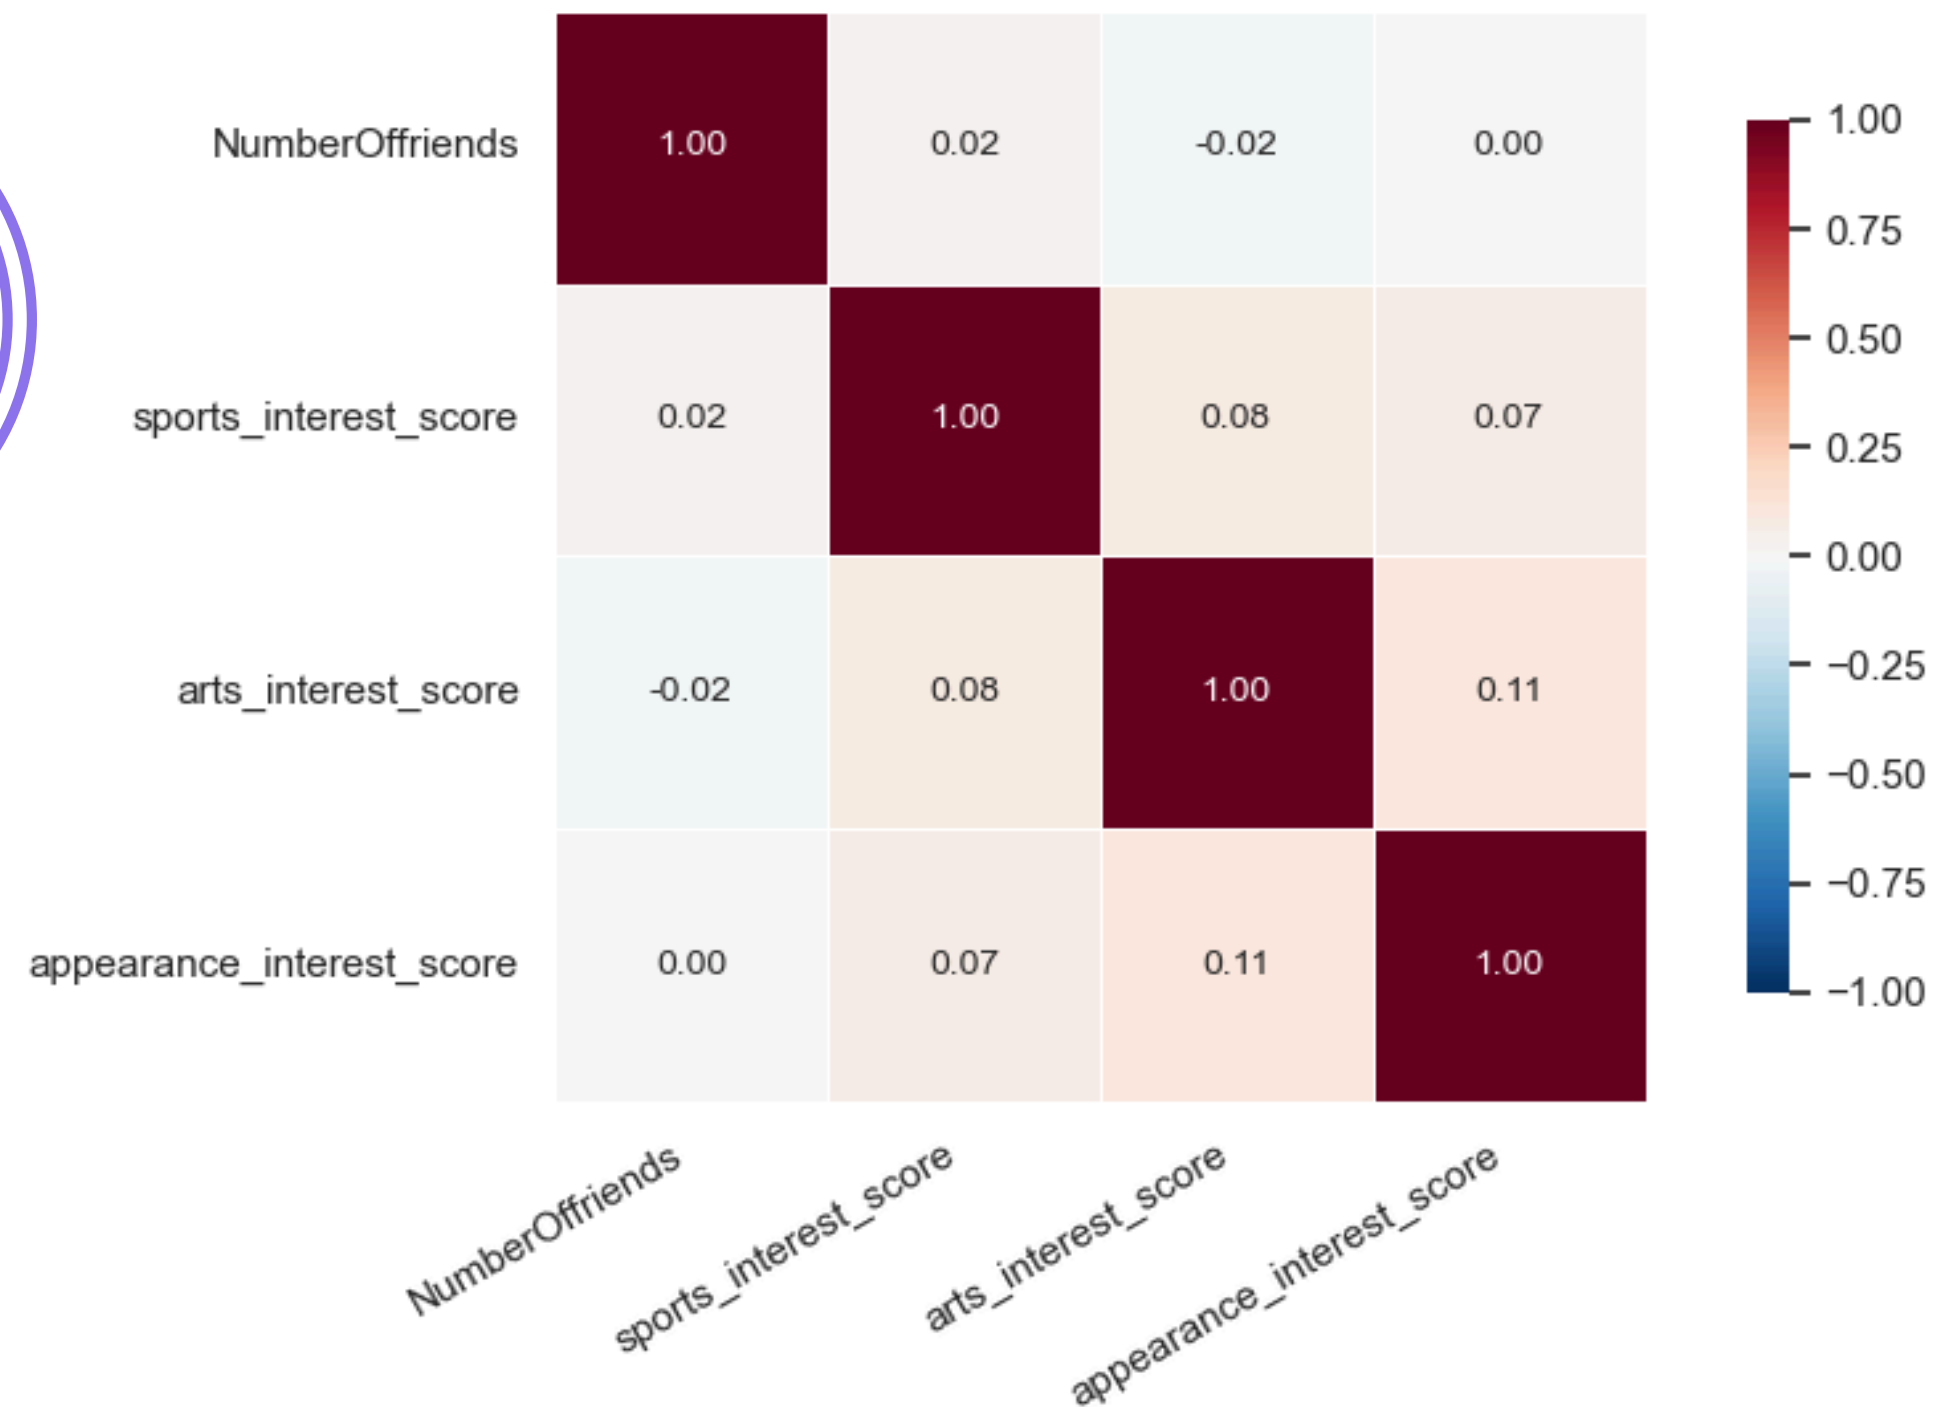
- Siswa dengan minat **olahraga (Sports)** memiliki rata-rata **jumlah teman tertinggi** dibandingkan minat lainnya
- Minat **Fashion dan Arts** menunjukkan rata-rata jumlah teman yang relatif berimbang
- Hal ini mengindikasikan bahwa **aktivitas yang bersifat kolektif dan kompetitif**, seperti olahraga, cenderung **mendorong interaksi sosial yang lebih luas** di media sosial



- Mayoritas siswa tergolong **Creative Student**, dengan jumlah yang jauh lebih besar dibanding persona lainnya
- **Low Social dan General Student** membentuk kelompok menengah dengan jumlah yang relatif seimbang
- **Popular Athlete** merupakan persona dengan jumlah paling sedikit, namun **berpotensi memiliki karakteristik sosial yang sangat aktif**



Correlation Between Social and Interest Features



- Jumlah teman **tidak berkorelasi kuat** dengan jenis minat tertentu
- **Korelasi antar minat** bersifat **positif** namun sangat **lemah**
- Korelasi **rendah** antar fitur menandakan **minim multikolinearitas**
- Kondisi ini menguntungkan untuk clustering, karena setiap variabel berkontribusi **secara independen**
- Segmentasi siswa **tidak hanya ditentukan** oleh satu aspek minat tertentu



## Pemilihan Feature

- ✓ **Fitur Numerik:** Graduation Year, Number of Friends Interest Features (Sports, Arts, Appearance)
- ✓ Bertujuan untuk memastikan model clustering bekerja optimal dan menghasilkan segmentasi yang interpretatif

## Feature Scalling (Standarisasi)

- ✓ **Tujuan Standarisasi :** menyamakan skala antar fitur, mencegah fitur dengan nilai besar mendominasi clustering
- ✓ Menggunakan **StandardScaler**, mengubah fitur menjadi: **Mean** = 0 ; **Standard Deviation** = 1

# PCA Analysis




- Mengambil 2 komponen utama (PC1 & PC2)
- Hasil :
  - PC1 menjelaskan sekitar **89% variasi data**
  - PC2 menjelaskan sekitar **8% variasi data**
  - Total variansi yang dijelaskan  $\approx$  **97%**

## Tunning Hyperparameter


- **Silhouette score** tertinggi k = 2
- Elbow method menunjukkan titik optimal di k=5
- **Elbow method** memberikan segmentasi yang **lebih granular dan interpretatif**
- Algoritma clustering yang digunakan: **K-Means**



# Cluster Visualization



Distribusi Anggota Cluster



**total\_members** **count**

|   |      |
|---|------|
| 2 | 4297 |
| 1 | 4193 |
| 4 | 1148 |
| 3 | 1125 |
| 0 | 288  |

- **Total cluster: 5**
- Setiap cluster merepresentasikan **pola sosial & minat** siswa yang berbeda
- Perbedaan utama terlihat pada:
  - **Jumlah teman**
  - Intensitas minat **olahraga, seni, dan penampilan**

# Cluster Profiling



## Artistic Social Students

- Rata-rata jumlah teman:  $\pm 32$
- Arts interest score paling tinggi ( $\approx 9.4$ )
- Minat olahraga relatif rendah-sedang
- Tingkat is\_artistic = 100%

Merepresentasikan siswa yang **sangat aktif di bidang seni, kreatif, dan cukup sosial.**



## Moderately Social Balanced Students

- Jumlah teman relatif rendah ( $\pm 24$ )
- Skor minat olahraga, seni, dan penampilan seimbang tapi rendah
- Tidak ada minat yang sangat dominan, bukan sporty ekstrem atau artistic ekstrem

Mencerminkan siswa dengan **pola minat seimbang namun tidak menonjol**, serta keterhubungan sosial yang moderat



## Low Engagement Students

- Jumlah teman relatif rendah ( $\pm 24$ )
- Skor minat olahraga, seni, dan penampilan paling rendah
- Aktivitas sosial dan minat sangat minimal

Menunjukkan kelompok siswa dengan **tingkat keterlibatan sosial dan minat yang rendah.**

Cenderung pasif dalam mengekspresikan minat maupun membangun koneksi sosial.

# Cluster Profiling



## Highly Sporty & Active Students

- Jumlah teman tinggi ( $\pm 33$ )
- Sports interest score sangat tinggi ( $\approx 7.18$ )
- Aktivitas olahraga (basket, football, soccer, softball) dominan

Merepresentasikan siswa yang **sangat aktif dalam olahraga dan memiliki keterhubungan sosial yang kuat**




## Highly Social Networkers

- Jumlah teman paling tinggi ( $\pm 111$ )
- Minat olahraga, seni, dan penampilan relatif sedang
- Tidak ada minat dominan, tapi sangat terkoneksi

Menunjukkan siswa yang **sangat aktif membangun jaringan sosial, terlepas dari minat tertentu.**



|          | gradyear | gender | NumberOfriends | basketball | football | soccer | softball | volleyball | swimming | cheerleading | ... | rock | hair | dress | blonde |
|----------|----------|--------|----------------|------------|----------|--------|----------|------------|----------|--------------|-----|------|------|-------|--------|
| clusters |          |        |                |            |          |        |          |            |          |              |     |      |      |       |        |
| 0        | 2007.46  | 1.82   | 32.50          | 0.20       | 0.34     | 0.18   | 0.21     | 0.12       | 0.19     | 0.06         | ... | 0.45 | 0.66 | 0.19  | 1.24   |
| 1        | 2008.52  | 1.82   | 24.26          | 0.24       | 0.19     | 0.23   | 0.16     | 0.13       | 0.16     | 0.11         | ... | 0.27 | 0.46 | 0.08  | 0.09   |
| 2        | 2006.48  | 1.78   | 24.27          | 0.19       | 0.20     | 0.20   | 0.13     | 0.10       | 0.14     | 0.08         | ... | 0.24 | 0.37 | 0.18  | 0.07   |
| 3        | 2007.78  | 1.76   | 32.94          | 1.41       | 1.39     | 0.82   | 0.73     | 0.70       | 0.31     | 0.26         | ... | 0.81 | 1.54 | 0.24  | 0.37   |
| 4        | 2007.78  | 1.89   | 111.01         | 0.23       | 0.24     | 0.28   | 0.16     | 0.17       | 0.17     | 0.30         | ... | 0.20 | 0.44 | 0.16  | 0.12   |




Nilai **silhouette score** sebesar **0.06** menunjukkan bahwa:

- Cluster tidak terpisah secara tegas
- Banyak data beririsan antar cluster
- Struktur data kompleks & heterogen

Hal ini sejalan dengan karakteristik data sosial yang **bersifat kompleks** dan **multidimensional**.

Oleh karena itu, clustering digunakan sebagai alat **segmentasi eksploratif** untuk **memahami pola perilaku siswa**, bukan sebagai **klasifikasi dengan batas yang kaku**.





# THANK YOU!!



***Get in  
Touch!***



+62895396345070



mayraatika@gmail.com



mayraafti



**Github**



**Canva**